

國立政治大學資訊管理學系

碩士學位論文

指導教授：姜國輝博士

以循環生成對抗網路預測股價量能動態關係

Using Cycle GAN to predict dynamic correlation
between price and volume

研究生：林奕廷

中華民國一〇八年七月

摘要

預測股價漲跌幅是投資人需要的資訊。技術分析方法種類眾多，當中量價關係為其主流方法之一。本研究使用 2007 年至 2017 年 台積電股票資料，運用首次提出的方法來觀察量價關係，透過循環生成對抗網路(Cycle GAN)結合卷積網路(Convolution Neural Network)與殘差網路(Residual Neural Network)學習量價間的聯合(joint)作用，並得出潛在量價。並參考系統動態學(system dynamic)，將潛在量價與目前量價的位能差距作為影響質量的勢能，透過神經網路轉換成推力， 市值、稅金、昨日漲跌幅視為質量、摩擦力、彈簧力，模擬現實股價上漲下跌的因素。

關鍵字：量價關係、系統動態學、循環生成對抗網路、技術分析

Abstract

The increasing demands for stock market prediction plays an important role in nowadays. Via Price -Volume Relation, we are able to access more insight for investors. We propose a novel generative model based on cyclic-consistent generative adversarial network (CycleGAN), which consists of Convolution Neural Network(CNN) and Residual Network(RESNET) for stock market prediction, in particular, Price-Volume Relation. In the reference to system dynamic, we can simulate potential fluctuation of current stock market via Neural network. Considering all the factors of stock market fluctuation e.g. value of stocks, tax, and current price changes as massive, friction, and spring force in system dynamic, our model is able to simulate the fluctuation and gain the ideal forecast. Our research is based on 2007-2018 TSMC stock dataset. For user friendly purpose, we compose BBands (Bollinger Bands) and stock price prediction model to use its derived indicator , %b indicator, to make trade signal. With BBands and our stock price prediction model, its average ROI(Return on investment) has increased 30% efficiency, which is the better result with merely BBands base on our experiment

第一章 緒論

技術分析是一種交易學科，用於評估投資，並且透過分析從交易活動(如價格變動和交易量)中收集到的資料來識別交易機會。

與試圖評估證券內在價值的基本分析不同，技術分析專注於價格變動、交易信號、以及各種不同的分析圖表工具來評估證券的優勢或劣勢。

過往研究指出，量價關係是一種特別的關係，擁有著聯合作用，單看一項終究導致失敗或不完整的結果。[13]而近幾年來神經網路發展迅速，許多深度學習(Deep Learning)的方法與獨特的網路架構被提出，在各大領域上有卓越的表現。目前有許多神經網路應用在預測股價方面上，較常見的是使用長短期記憶(LSTM)架構，不過通常都將量與價視為一種資料而非兩個具有獨特關係的資料。因此本研究想要嘗試使用深度學習來學習量價間的關係，再應用此結果預測股價，進而達到技術分析的目的。

主要來說我們的貢獻有兩種：

1. 使用循環生成對抗網路來觀察量價關係，並且證明量價關係可以被此神經網路所學習。
2. 透過假設循環生成對抗網路的結果來預測股價。

第二章 文獻探討

第一節 生成對抗網路(Generative Adversarial Network , GAN)

GAN 包含兩個模組：一個生成(Generative)模組與一個鑑別(Discriminator)模組。鑑別模組是一個分辨器，用於確定給定的圖像是從訓練數據集來的真實圖像或是人工(artificially)創建的圖像。這是一種二分類器，普遍採用卷積神經網路所建。

而生成模組會接受隨機輸入值並且將他們透過反卷積神經網路轉換成圖像。

GAN 成功的關鍵是對抗損失的點子，這使得生成的圖像跟真實圖像難以分辨。這種類型的損失(loss)對於生成圖像的任務特別有用，正因為是所有電腦圖學旨在優化的目標。

第二節 循環生成對抗網路(Cycle GAN)

圖像到圖像轉換是視覺和圖形問題之一，其目標是使用配對圖像的訓練集來學習輸入圖像與目標圖像之間的映射。但是，對於許多任務，沒有可以使用配對的訓練數據。循環生成對抗網路就是為了解決這種窘境所提出的方法，用於學習在沒有配對範例的情況下將圖像從領域 X 轉換為領域 Y

在此有兩個前提：

1. 沒有提供領域 X 與領域 Y 配對的資訊 (unpair)
2. 假設 X 與 Y 的領域存在潛在的關係

他們研究發現很難優化獨立的對抗目標：一般標準程序的訓練會導致廣為人知的崩潰問題，也就是所有的圖像都被映射到同樣的輸出圖像，導致優化無法進展。所以為了解決這個而加入了更多結構。數學上，如果我們有個轉換器 $G(X) \rightarrow Y$ 和另一個轉換器 $F(Y) \rightarrow X$ ，那麼 G 跟 F 是相互反轉，並且兩種映射也是雙射(bijections)。我們藉由同時訓練映射 G 跟 F 來應用這種結構假設，並且加入循環一致性損失(Cycle consistency loss)，這會鼓勵 $F(G(x)) \approx x$ 且 $G(F(y)) \approx y$ 。結合這種損失跟對抗損失在領域 X 和 Y 上可以達到我們的最終目標，也就是沒配對的圖像對圖像轉換。

第三節 殘差網路 (Residual Neural Network, ResNet)

深層網路主要被提出來解決兩個問題：1. 梯度消失(gradient vanishing) 2. 梯度去除(degradation)，前者主要述說在梯度過於微小的情況下，會導致反向傳播(Back Propagation)無法收斂到最佳值，後者則是梯度無法反向傳播，導致誤差累積，以致越深層的網路，誤差值越高。為了解決這兩種情況，在 2016 年由何愷明 (Kaimei He) 博士就提出 Residual Neural Network(ResNet)。它是由 Residual Block 所組成，除了和原本網路有相同的架構以外，另外還會有條捷徑連結。




圖 1、Residual Block

在此假設原本期望的輸出為 $H(x)$ ，此層神經網路輸出為 $F(x)$ ，假設 $H(x) = F(x) + x$ ，此篇論文證實透過此 Block 的輸出 $H(x)$ 使神經網路整體優化更佳。

第四節 Long Short-Term Memory (LSTM)

LSTM 是 Recurrent Neural Networks (RNN) 的一種變形，RNN 與一般神經網路不同的地方有著隨時間變化的隱藏狀態。當使用 Back Propagation 訓練的時候，RNN 會遇到梯度消失的問題，使他無法處理時間序(Time Series)資料中的長期依賴性，所以 LSTM 被提出來解決這個問題。它比 RNN 多出了閘門，用來處理長期依賴性。

第五節 量價關係

1. 量價之間的關係

量價齊漲、齊跌指的是股價與成交量呈正相關。Ying(1966)以 NYSE 的交易資料做研究，表明量是價的先行指標，在交易量少的時候，股價通常會下跌的，反之亦然。

量價背離，指的是股價與成交量呈負相關。Sheu et al.(1998)以台灣股票做研究，表明股市期望報酬率與交易量具有可靠的負向關係。

2. 股價與成交量有聯合作用

Ying(1966) 提到價格與交易量的關係被認為是單一市場機制下的聯合產品，任何只單看股價、交易量的模型最終會產生錯誤的結果或不完整的結果。

Sheu et al.(1998)交易量與價格似乎再解釋平均回報的橫截面(cross-section of average returns)起到聯合作用。

第六節 系統動態學

系統模組有三種基本型態：Physical, analytical, 和 descriptive。最傳統也是最廣為人知的模組是物理系統。其優勢為可以使用他們進行實驗測試，但缺點是可能所費不貲。

在這裡我們使用其中幾個模擬元件：

1. Mass (質量)

當提到術語牛頓的第二運動定律，質量 M 是被公式所定義。

公式： $f = M \frac{dv}{dt} = Ma$ ， v 是速度， d 是微分， t 是時間， M 是質量。




圖 2 質量元件

2. Damper(摩擦力)

有三種不同重要的摩擦力機制：靜態，庫倫，和黏性，在此研究用到靜摩擦力

靜摩擦力與運動有直接關係，並且透過在兩個接觸表面之間所啟動之運動狀態表現出來。

公式： $f = Dv$ ， D 是摩擦力常數， v 是速度。




圖 3、摩擦力元件

3. Spring(彈簧)

彈簧元件是由於施力引起的彈力變形而在位移中儲存能量的元件。

公式： $f = K \int v dt$ ， K 是彈簧常數、 v 是速度， d 是微分， t 是時間。



圖 4、彈簧元件

第三章 研究方法

利用網路爬蟲來抓取台灣證券交易所上台積電股價資料，範圍從 2007~2018 年，透過正規化與資料處理後，放入神經網路做監督式學習量價間的關係，再透過模擬系統動態學與前述結果做股價預測。最後驗證所有步驟的效果。

第一節 資料蒐集

本研究使用 Slenium 網路爬蟲軟體配合 Beautiful soup 進行資料擷取，抓取台灣證券交易所半導體業資訊，包括證券代號、證券名稱、成交股數、成交筆數、成交金額、開盤價、最高價、最低價、收盤價、漲跌...等，抓取範圍為 2007 年到 2018 年。

第二節 資料前處理

1. 股價與交易量正規化

交易量的值域與股價值域數值不同，若直接照一般方法正規化，會導致兩者之間數值的差距過大，進而影響後續的循環生成對抗網路。為了降低此種影響，將資料轉換成變化量，再對其取 log，降低差距。最後再透過 Min-Max 正規化方法使其資料範圍介於 0~1 之間。

其中 Min-Max 正規化公式為：

$$zi = \frac{xi - \min(x)}{\max(x) - \min(x)}$$

2. 直接正規化

其餘資料除了市值以外皆直接使用 Min Max 正規化。市值由於後續模擬系統動態學時會當作除數使用，因除數不得為 0，故將正規化後的結果透過此公式轉換：

$$zi = \frac{xi + 1}{2}$$

使其值域範圍為 0.5 ~ 1 之間。

3. 訓練/驗證/測試資料切割

為了避免模型產生所謂的過擬合(Over fitting)的問題，在此將資料切割成三個部分，其中訓練資料包含 2007 年 ~ 2014 年資料，驗證包含 2015、2016 年資料，最後測試則是 2017、2018 年資料。

第三節 神經網路設計

1. 循環生成對抗網路 設計

過往研究指出，量價之間具有聯合作用，任何只使用其中一種資料的模型的結果會不正確。為了學習量價間的關係，本研究提出使用循環生成神經網路學習此種關係，透過其中核心機制，循環損失(Cycle loss)，其損失函數為：

$$L_{cyc}(G, F) = E_{x \sim p_{data}(x)} [||F(G(x)) - x||_1] + E_{y \sim p_{data}(y)} [||G(F(y)) - y||_1].$$

對於每個來自領域 X 的圖像，應能透過其循環機制，回到原始的圖像。即 $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$ 。而我們核心想法也來自於此，透過轉換領域來學習量價間的聯合作用。循環生成網路另一個核心機制為對抗損失，損失函數為：

$$L_{GAN}(G, D_Y, X, Y) = E_{y \sim p_{data}(y)} [\log D_Y(y)] \\ + E_{x \sim p_{data}(x)} [\log(1 - D_Y(G(x)))]$$

其中 G 嘗試將產生的圖像 $G(x)$ 變得像從領域 Y 來的圖片，而 D_Y 嘗試分辨轉換樣本 $G(x)$ 以及真正領域 Y 的樣本。

此網路全部的目標為：

$$L(G, F, D_X, D_Y) = L_{GAN}(G, D_Y, X, Y) + L_{GAN}(F, D_X, Y, X) + \lambda L_{cyc}(G, F)$$

而最終要解出：

$$G^*, F^* = \arg \min_{G, F} \max_{D_X, D_Y} L(G, F, D_X, D_Y)$$

故在此將價格當作領域 X ，交易量當作領域 Y 做為循環生成對抗網路的輸入。

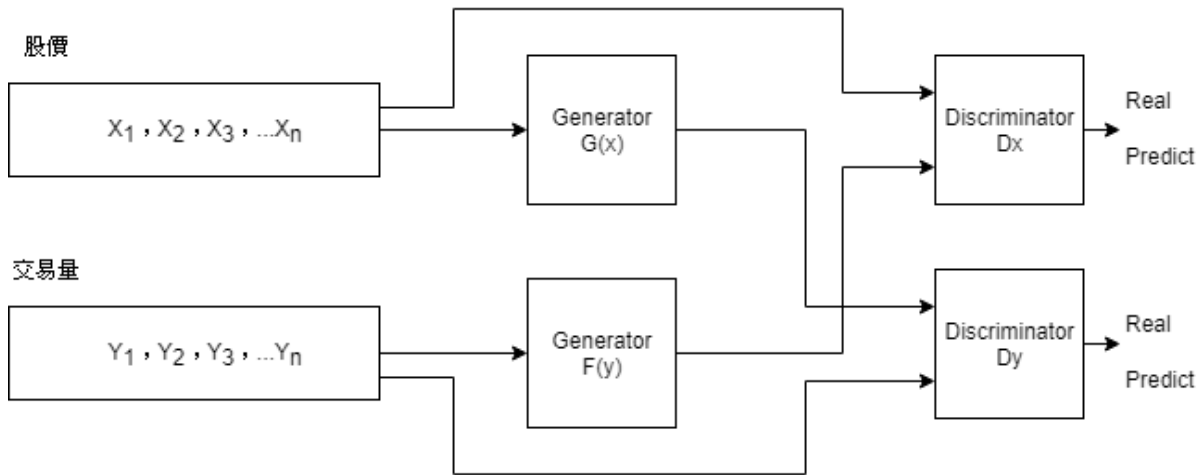


圖 5、整體循環生成對抗網路設計圖

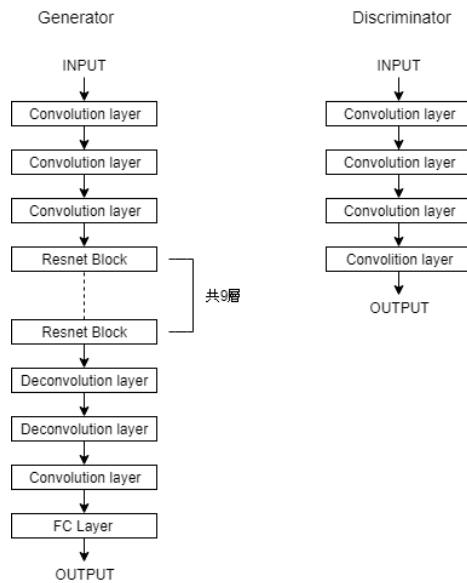


圖 6、Generator 與 Discriminator 的設計圖

FC 指的是 Fully Connective layer 的縮寫，其中股價與交易量是有作重塑矩陣，使之成為二維度矩陣的模擬圖的資料做為 Generator 與 Discriminator 的輸入。

由於循環生成對抗網路原先使用在圖像領域互相轉換上，在此先將資料轉換為模擬圖的二維資料，透過對圖像有良好效果的 CNN 與深度學習網路 RESNET 結合的架構做

為 Generator，藉此觀察量價關係，產生足夠騙過 Discriminator 的作品。而 Discriminator 同樣使用 CNN 作為架構，以便估計二維資料是來自實際的資料或是由 Generator 所產生的假作品。

2. 模擬系統動態學預測股價

我們運用了新的觀點來了解量價關係與股價未來趨勢，假設前述神經網路的產生的假作品 $G(x)$ 、 $F(y)$ 為目前量價的潛在量價，也就是目前量價未來的趨勢。假設潛在量價與目前量價位能不同，會使物體有移動的勢能，也就是股價上漲下跌的力量。為了實現位能轉換動能推動物體，本研究參考系統動態學模擬如下。

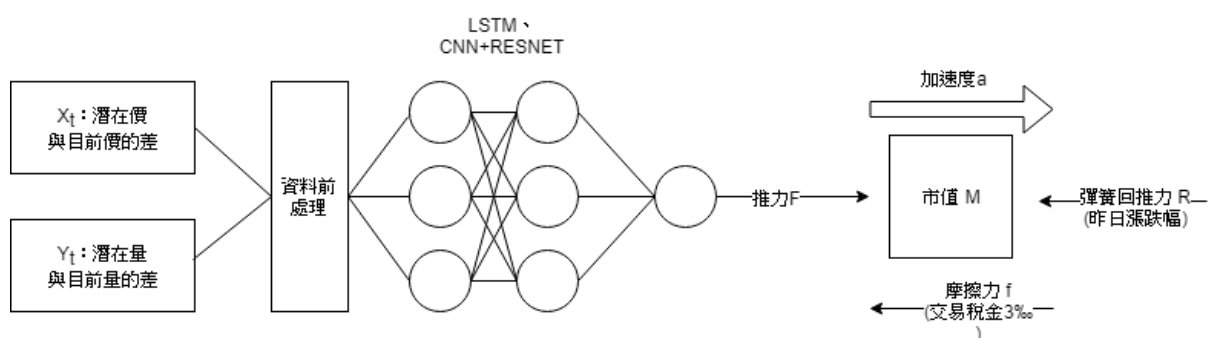


圖 7、模擬系統動態學

A. 推力 F

X_t 是由假作品 $F(y)$ ，潛在價與目前價相減得出； Y_t 則是由假作品 $G(x)$ ，潛在量與目前量相減得出。我們透過輸入 X_t 、 Y_t 至神經網路來模擬位能轉動能的推力 F。

B. 市值 M

市值為股票價格 * 發行張數。

將市值當作物體讓推力 F 推動，股票市場中，股價的成長幅度與市值以及資金流入有關，相同資金流入不同市值有不一樣的股價成長幅度。因此將市值其當作物體藉此模擬當相同推力推動不同市值時，所形成加速度、改變股價的幅度也會有所不同。

C. 摩擦力 f

3‰稅金，也就是交易量 * 股價 * 3‰。

在系統動態學中，摩擦力跟推力有關，在股市交易實務上，可視為交易稅金。因股價的上漲下跌的力量來自於籌碼，但流入股票市場前會先扣稅，故將交易稅作為摩擦力。

D. 回彈作用力 R

根據昨天漲跌幅給予相對應的數值。

在系統動態學，彈簧回彈力與儲存位能有關。股票漲跌為一個連續性的影響，其中昨日漲跌幅影響未來股價最大。假設昨日大漲會使得彈簧儲存位能較多，使得未來股價較不易繼續上升，而反之亦然。

E. 加速度 a

由距離公式得出加速度 a，假設初速皆為 0，k 為欲預測幾天後的股價。公式如下：

$$a = 2(\text{data}_{t+k} - \text{data}_t)/t^2$$

3. 無模擬系統動態學預測股價

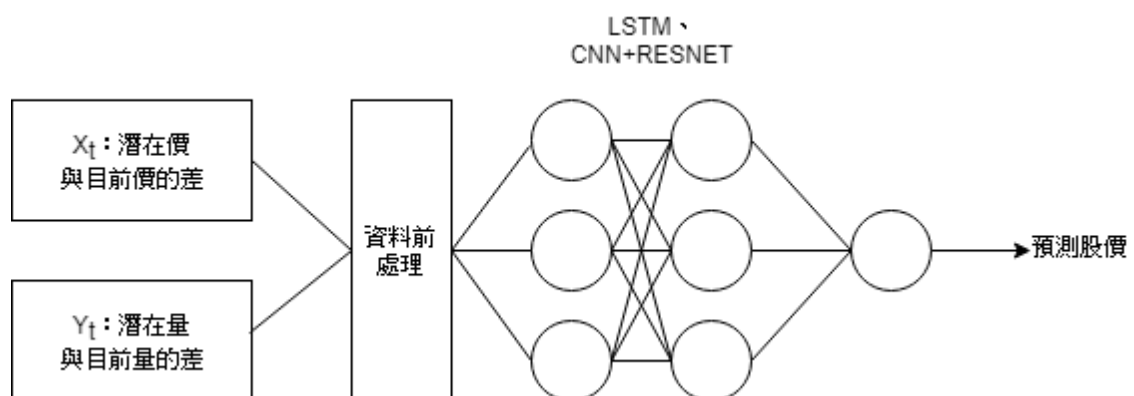


圖 8、無模擬系統動態學的神經網路架構

在此將潛在量價與目前量價的差做為未來股價的趨勢，透過與模擬系統動態學與一樣的神經網路設計預測未來股價，並與之比較預測股價效果。

4. 神經網路設計

A. 運用 RESNET 建構神經網路

透過 CNN 萃取特徵值與 RESNET 的深層網路做連接，在此是使用 n 天的還原價、量，所以將 RESNET 層數也設計為 n 層。




圖 9、RESNET 網路設計圖

B. 運用 LSTM 建構神經網路

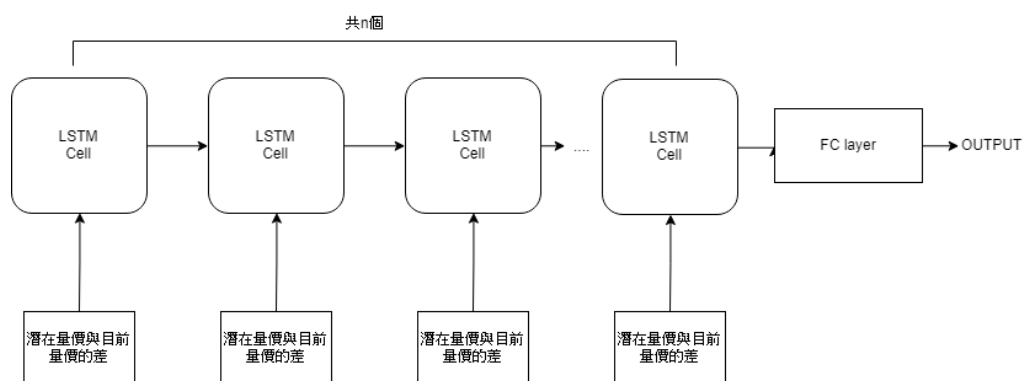


圖 10、LSTM 架構圖

藉由 LSTM 觀察還原量價的時序資料，得出推力 F。雖然其複雜度不及 CNN+RESNET，但此模型更適合觀察時序資料，可以期待效果跟 CNN+RESNET 相同甚至更好。

第四章 實驗結果

第一節 模型評估

我們會使用不同模型來預測下個時間點的股價。在此我們用三種方式來評估我們的模型。

1. MSE(Mean Squared Error)

計算真實數值與預測值的平方差距的期望值，MSE 不僅可用於評估模型，也提供類神經網路較良好的梯度來收斂。期望在相同學習率(learning rate)下，損失(loss)越靠近 0，梯度也會越小。

2. MAE(Mean Abs Error)

計算真實數值與預測值得差距的期望值，MAE 更能反映出預測值與真實數值誤差的實際情況。

第二節 環生成對抗網路學習量價關係成果




圖 11、循環生成對抗網路損失

在此可以得知 Generator G 的 loss、Generator F 的 loss 以及 Cycle loss 隨著 epoch 的增加，loss 顯著降低。並假設 Cycle loss 是 Hyper Parameter，將其訓練到一個程度後便不再訓練。

表格 一：循環生成對抗網路損失(MSE)

	訓練 Cycle_loss	驗證 Cycle_loss	測試 Cycle_loss
20 天	0.031995635	0.038789876	0.036866438
30 天	0.016229397	0.016477194	0.015846474
40 天	0.0015571207	0.031062838	0.030280465

由此可見，RESNET 的網路架構可以將量價關係學習良好，測試 Cycle loss 其結果也有顯著降低，顯示量價關係是可以由循環生成對抗網路所學習的。30 天的量價作為輸入可以獲取最低的損失值，其訓練、驗證以及測試的 Cycle loss 皆為最低，並且其中差距也不大，故此將先前提到神經網路的參數 n 設定為 30。

表格 二 RESNET 預測股價的平均差距(MAE)

	訓練	驗證	測試	平均
RESNET 無模擬系統動態學 無正規化目標資料	1.951394	3.345	5.097	3.464465
RESNET 模擬系統動態學 無正規化目標資料	3.211395	4.104	5.390600	4.235332
RESNET 無模擬系統動態學 正規化目標資料	1.9069737	3.999800	5.346600	3.7511246
RESNET 模擬系統動態學 正規化目標資料	15.592605	9.153	12.2104	12.318668

表格 三 LSTM 預測股價的平均差距(MAE)

LSTM 無模擬系統動態學 無正規化加速度	1.995237	3.380000	5.080200	3.485146
LSTM 模擬系統動態學 無正規化目標資料	3.5186053	3.760200	5.308800	4.1958684
LSTM 無模擬系統動態學 正規化目標資料	2.002026	3.356000	5.073000	3.477009
LSTM 模擬系統動態學 正規化目標資料	11.24382	13.5698	18.659800	14.49114

第三節 預測股價結論

預測股價表現在於正規化/無正規化、有無模擬系統動態學中表現各有千秋。

- a. 對於在模擬系統動態學下，若目標資料正規化後，RESNET 深層神經網路相較於 LSTM 下，對於目標資料學習能力較佳，但無正規化的學習能力較差。但若無目標資料正規化，則是 LSTM 表現較佳。
- b. 至於在無模擬系統動態學下，若將目標資料正規化後，影響 RESNET 的結果較多，雖然使訓練損失下降，但其驗證、測試損失皆上升，平均結果較差。反而對於 LSTM 較無影響，其訓練、驗證、測試損失皆無太大差距。
- c. 整體而言，在有模擬系統動態學下 LSTM 最佳表現優於 RESNET，其驗證、測試之損失比起對方皆較接近訓練損失，平均損失 4.1958684 也優於對方 4.235332。但無模擬系統動態學下 RESNET 與 LSTM 相差不多，期訓練、驗證、測試損失差異不大，但就平均損失而言 RESNET 之損失 3.464465 稍微優於對方 3.477009。
- d. 以結果來說，在無模擬系統動態學下可以獲得最低與預測股加之差距，RESNET 配合無正規化目標資料得到最佳結果 3.464465。

第五章 研究結論與建議

第一節 結論

本研究利用神經網路預測股價，針對 2007 年 01 月 01 日至 2018 年 12 月 31 日台積電股票資料進行預測，並利用量價關係、模擬系統動態學，證實結合預測股價的布林帶

之投資報酬率有所提升。歸納結論如下：

- 本研究首次提出運用量價關係的潛在結構，透過循環生成對抗網路結合卷積層與殘差網路，觀察並學習量價關係。實驗證明此網路確實有學到量價之間的聯合作用。
- 實驗測試 20、30、40 天的量價輸入至循環生成對抗網路，結果表明使用 30 天的量價可獲得最低的 Cycle loss。
- 將循環生成對抗網路學習的結果整合系統動態觀點，假設潛在量價與目前量價位能不同，會形成動量影響未來股價，藉由模擬系統動態學來實現；另一方面則是假設循環生成對抗網路的結果是未來量價的趨勢，藉由輸入至神經網路來實現預測股價。實驗發現後者預測股價較準，其預測股價誤差皆低於前者。
- 接續上結果，後者 RESNET 預測 5 日後(周線)股價是實驗中表現最好的，與股價的平均誤差為 3.464465，而 LSTM 為 3.477009，略高於前者。

第二節 未來建議

針對本研究不足之處，在此提出未來可改進與發展方向：

- 從資料著手，透過蒐集國外更多股票資料來比較國內外市場是否具有相同效果，或是國內交易量較低的股票資料，進一步驗證此方法泛用性。
- 神經網路模型方面與模擬系統動態學，本研究使用 RESNET 與 LSTM 做預測股價，但使用模擬系統動態學的表現皆輸給只單純使用神經網路的預測，或許未來可以考慮更多參數進入，使其預測股價表現更佳。

參考文獻：

1. 胡依淳，民 107，深度卷積神經網路中卷積層之分析及比較。國立暨南國際大學電機工程學系碩士論文。
2. 高士軒，民 97，「價量關係：量是否為價格發現的先行指標」，逢甲大學財務金融學所碩士論文。
3. 陳盈臻，民 102。台灣股票市場量價背離之實證研究，佛光大學管理學系碩士論文。
4. Ahmed, A. S., Schneible, R. A. J., and Stevens, D. E. 2003. An Empirical Analysis of the Effect of Online Trading on Stock Price and Trading Volume Reactions to Earnings Announcements. *Contemporary Accounting Research*, 20, 413-439.
5. Crouch, R. L. 1970. The volume of transactions and price changes on the New York
6. DeMark, T. R. 1984. *The New Science of Technical analysis*. New York : John Wiley and Sons, Inc.
7. Gers, F. A., Schmidhuber, J., & Cummins, F. 1999. Learning to forget : Continual prediction with LSTM.
8. Goodfellow, Ian, et al. 2014. "Generative adversarial nets." *Advances in neural information processing systems*.
9. Granger, C. W. J., and Morgenstern, O. 1963. Spectral Analysis of New York Stock Market Prices. *Kyklos*, 16, 1-27.
10. He, Kaiming, et al. 2016. "Deep residual learning for image recognition." *Proceedings of the IEEE conference on computer vision and pattern recognition*.
11. Seely, Samuel. 1972. *An Introduction to Engineering Systems*.

12. Sheu, Her-Jiun, Wu, Soushan and Ku, Kuang-Ping 1998. The cross-sectional relationships between stock returns and market beta, trading volume sales-to-price in Taiwan. *International Review of Financial Analysis*, 7, 1-18.
13. Ying, C. C. (1966). Stock Market Prices and Volumes of Sales. *Econometrica*, 34, 676-685.
14. Zhang, Liheng, Charu Aggarwal, and Guo-Jun Qi. 2017. "Stock price prediction via discovering multi-frequency trading patterns." *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
15. Zhu, Jun-Yan, et al. 2017. "Unpaired image-to-image translation using cycle-consistent adversarial networks." *Proceedings of the IEEE International Conference on Computer Vision*.
16. 網頁資料 Jon Bruner “Generative Adversarial Networks for Beginners”(https :
//github.com/jonbruner/generative-adversarial-networks/blob/master/gan-notebook.ipynb)
17. 網頁資料 ADAM HAYES “Technical Analysis Definition”(https :
//www.investopedia.com/terms/t/technicalanalysis.asp)
18. 網頁資料 “布林帶”(https :
//zh.wikipedia.org/wiki/%E5%B8%83%E6%9E%97%E5%B8%A6)